Relatório Técnico — Segmentação de Tumores Cerebrais em Imagens de Ressonância Magnética

Rafael Lazarin Lobo de Almeida

1. Introdução

Este trabalho foi desenvolvido como desafio final do bootcamp de Visão Computacional. O objetivo foi criar e comparar modelos capazes de identificar regiões de tumor em imagens de ressonância magnética cerebral.

Para isso, foi utilizado o dataset LGG MRI Segmentation, disponível no Kaggle. O dataset possui imagens de ressonância e máscaras que indicam onde o tumor está presente.

Durante o projeto foram realizados três experimentos. Primeiro foi criado uma U-Net simples usando os dados praticamente sem alterações, para servir como baseline. Depois foi testada a mesma U-Net com Data Augmentation e normalização. Por último, foi utilizada uma U-Net com encoder ResNet34 pré-treinado no ImageNet.

---

2. Dataset

O dataset utilizado foi o LGG MRI Segmentation, disponível no Kaggle. Ele é formado por imagens de ressonância magnética cerebral e suas respectivas máscaras de segmentação.

Durante a análise inicial foram encontrados 110 pacientes, com um total de 3.929 imagens e 3.929 máscaras. Todas as imagens possuem resolução de 256 × 256 pixels.

Também foi analisada a quantidade de imagens com e sem tumor. Das 3.929 imagens, 1.373 possuem região tumoral, o que representa cerca de 34,95% do dataset, e 2.556 possuem máscaras vazias.

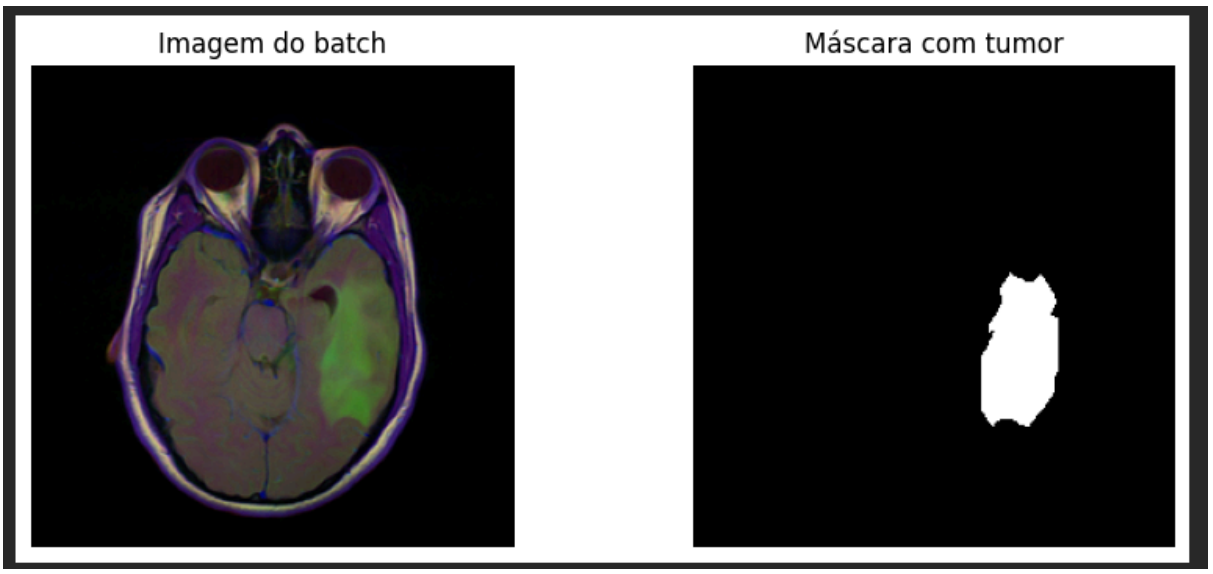


Figura 1 — Exemplo de imagem de ressonância magnética e respectiva máscara de segmentação tumoral.

---

3. Preparação dos dados

Primeiro, cada imagem foi associada à sua respectiva máscara e ao paciente ao qual pertencia.

A divisão entre treino, validação e teste foi feita por paciente, e não diretamente pelas imagens. Isso foi feito para evitar que imagens do mesmo paciente aparecessem ao mesmo tempo no conjunto de treino e no conjunto de teste, o que poderia influenciar os resultados.

Foram utilizados:

Conjuntos	Pacientes	Imagens
Treino	77	2.750
Validação	16	618
Teste	17	561

Foi utilizada uma semente fixa (SEED = 42) para que a mesma divisão pudesse ser reproduzida novamente.

As máscaras foram convertidas para valores 0 e 1, e os DataLoaders foram configurados com batch size igual a 8.

---

4. Pipeline de treinamento

Para que a comparação fosse justa, os três experimentos utilizaram a mesma divisão de pacientes e as mesmas métricas de avaliação.

A função de perda utilizada foi uma combinação entre BCEWithLogitsLoss e Dice Loss:

Loss = 0,5 × BCEWithLogitsLoss + 0,5 × Dice Loss

A BCE ajuda o modelo a decidir se cada pixel pertence ou não ao tumor, enquanto a Dice Loss ajuda a comparar a área prevista pelo modelo com a área real da máscara.

As principais métricas utilizadas foram Dice Score e Intersection over Union (IoU). Para transformar a saída do modelo em uma máscara binária foi utilizado um limite de 0,5.

Nos treinamentos também foi utilizado o otimizador AdamW, o ReduceLROnPlateau para diminuir a taxa de aprendizado quando necessário e o early stopping para interromper o treinamento caso o modelo deixasse de melhorar.

---

5. Experimentos

5.1 Experimento 1 — Baseline com dados crus

O primeiro experimento foi utilizado como baseline. Foi treinada uma U-Net simples, sem Data Augmentation e sem a normalização utilizada nos outros experimentos.

Foram feitas apenas as transformações necessárias para carregar as imagens no modelo.

A taxa de aprendizado inicial foi de 1×10^{-3}, utilizando AdamW. O treinamento foi configurado para até 15 épocas, sempre salvando o melhor modelo de acordo com a perda de validação.

Esse experimento serviu para saber se as mudanças feitas nos próximos testes realmente melhoraram os resultados.

5.2 Experimento 2 — U-Net com Data Augmentation e normalização

No segundo experimento foi mantida a mesma U-Net, mas foram adicionadas alterações no pipeline de dados.

Durante o treinamento foram utilizadas técnicas de Data Augmentation, como espelhamento horizontal, pequenas rotações, mudanças de escala, translação e alterações de brilho e contraste.

Também foi aplicada a normalização baseada nos valores do ImageNet. A taxa de aprendizado inicial continuou sendo 1×10^{-3}.

O objetivo desse teste foi verificar se essas alterações melhorariam o desempenho da U-Net em relação ao baseline.

5.3 Experimento 3 — U-Net com ResNet34 e Transfer Learning

No terceiro experimento foi utilizada uma U-Net com encoder ResNet34 pré-treinado no ImageNet.

Foi mantido o mesmo Data Augmentation e a mesma normalização do segundo experimento, mas agora o modelo também utilizava pesos já aprendidos anteriormente no ImageNet.

Como foi utilizado um modelo pré-treinado, a taxa de aprendizado foi reduzida para 1×10^{-4}.

Nesse experimento não foi alterado apenas o Data Augmentation. Também houve mudança de arquitetura e uso de Transfer Learning, então qualquer melhora não pode ser atribuída a apenas uma dessas mudanças.

---

6. Resultados

Depois dos treinamentos, o melhor modelo de cada experimento foi carregado e testado utilizando o mesmo conjunto de pacientes.

Os resultados foram:

Experimento	Test Dice	Loss	IoU
U-Net com dados crus	0,3916	0,6633	0,5570
U-Net + Augmentation/Normalização	0,4090	0,6303	0,5273
U-Net + ResNet34	0,3591	0,7908	0,6992

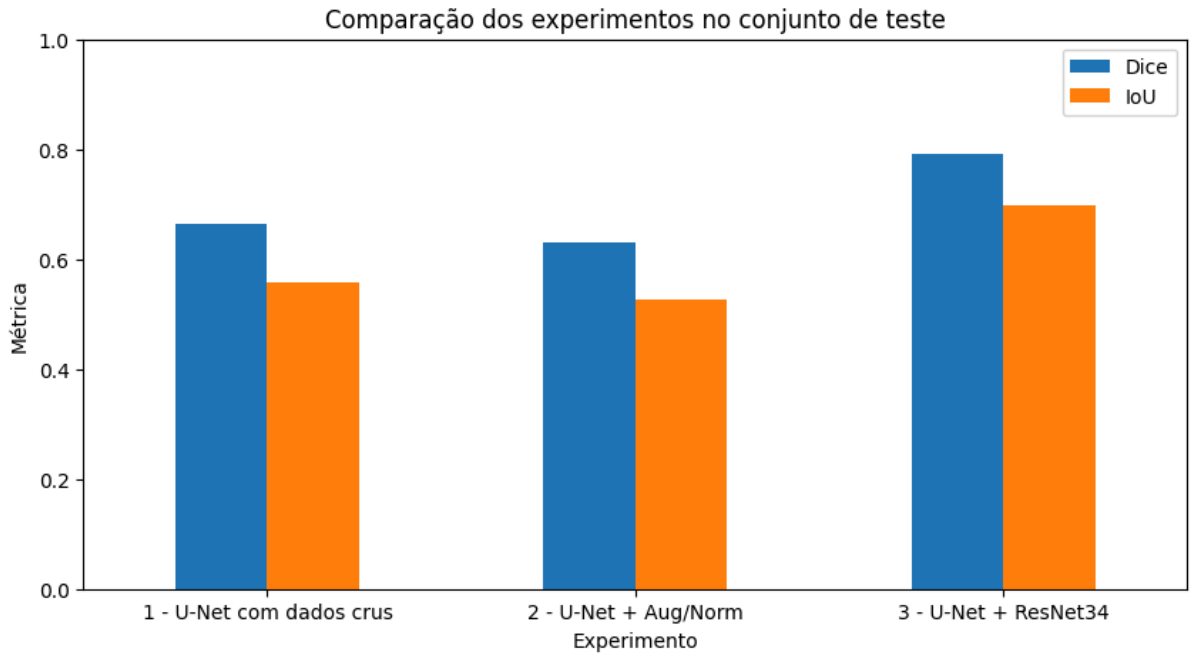


Figura 2 — Comparação das métricas Dice e IoU entre os três experimentos no conjunto de teste.

O baseline alcançou Dice de aproximadamente 0,66 e IoU de 0,56.

No segundo experimento, mesmo utilizando Data Augmentation e normalização, o resultado ficou um pouco abaixo do baseline, com Dice de aproximadamente 0,63 e IoU de 0,53.

Isso mostrou que adicionar Data Augmentation não significa automaticamente melhorar o modelo. Nesse caso, as transformações utilizadas não trouxeram ganho para a U-Net simples.

O melhor resultado foi obtido no terceiro experimento, com a U-Net utilizando ResNet34. O modelo alcançou Dice de aproximadamente 0,79, IoU de 0,70 e também teve a menor perda no conjunto de teste.

---

7. Avaliação qualitativa

Além das métricas, também foi feita a comparação visual entre a máscara real e as previsões dos três modelos.

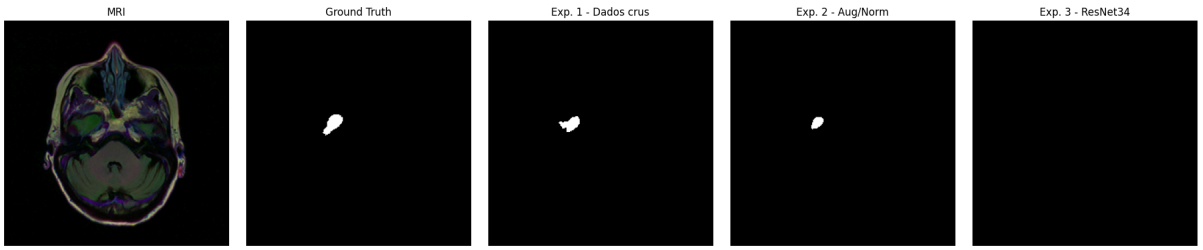


Figura 3 — Comparação qualitativa entre a máscara real e as predições dos três experimentos.

No exemplo escolhido, os modelos dos Experimentos 1 e 2 conseguiram identificar a região do tumor, enquanto o modelo com ResNet34 gerou uma máscara vazia.

Mesmo sendo o modelo com melhor resultado geral, a ResNet34 não foi melhor em todas as imagens.

Esse exemplo mostra por que é importante olhar tanto para as métricas quanto para as previsões feitas pelo modelo. Um modelo pode ter um resultado médio melhor e ainda cometer erros em imagens específicas.

---

8. Conclusão

Os experimentos permitiram comparar diferentes formas de realizar a segmentação de tumores nas imagens de ressonância magnética.

O primeiro modelo, utilizando uma U-Net simples e os dados sem Data Augmentation, serviu como baseline. No segundo experimento foram adicionados Data Augmentation e normalização, mas os resultados ficaram um pouco abaixo do baseline. Isso mostrou que adicionar novas técnicas ao treinamento não significa necessariamente melhorar o modelo.

O melhor resultado foi obtido com a U-Net utilizando ResNet34 pré-treinada, que alcançou Dice de aproximadamente 0,79 e IoU de 0,70.

Mesmo assim, na comparação visual foi possível observar um caso em que esse modelo não identificou o tumor, enquanto os outros dois conseguiram.

Por isso, além das métricas, também é importante observar as previsões feitas pelos modelos.

No geral, o projeto mostrou a importância de começar com um modelo simples e comparar cada alteração feita durante o desenvolvimento, para entender quais mudanças realmente melhoraram o resultado.

---

9. Materiais do projeto

O código, notebook completo, resultados e instruções de reprodução estão disponíveis no repositório público:

GitHub: https://github.com/RafaelILobo/Brain-MRI-Segmentation

O dataset utilizado:

LGG MRI Segmentation — Kaggle
Brain MRI segmentation | Kaggle